Sutton 强化学习

第1章：绪论与核心范式

- 核心交互范式
  - 智能体与环境交互闭环
  - 试错搜索
  - 延迟奖励
- 四大核心要素
  - 策略
  - 即时奖励
  - 价值函数
  - 环境模型（可选）
- 马尔可夫决策过程基础
  - 马尔可夫性质（无后效性：未来只取决于现在）
  - 不完全已知马尔可夫决策过程假设

第2章：多臂老虎机

- 核心矛盾与权衡
  - 利用：榨取当前已知最佳经验
  - 探索：尝试未知以发现更优动作
  - 真实价值与样本估计均值
- 主要动作选择方法
  - 贪婪选择（易陷入局部最优）
  - ε-贪婪策略（保持恒定随机探索）
  - 乐观初始值（驱动早期全面试错）
  - 置信区间上界（不确定性驱动探索）
  - 梯度老虎机（基于动作偏好度与策略梯度）
- 平稳与非平稳问题跟踪
  - 平稳环境：样本平均法
  - 非平稳环境：常数步长法（指数近因加权）
- 关联搜索（上下文老虎机，过渡至完整决策过程）

第3章：有限马尔可夫决策过程

- 智能体-环境动力学交互
  - 状态、动作与即时奖励
  - 四参数联合动力学函数与状态转移概率
- 智能体与环境的边界划分
  - 因果可控性准则（无法直接决定的均属于环境）
  - 执行机构物理约束与决策指令辨析
- 目标、回报与任务形式
  - 期望累积回报与折扣因子
  - 连续时刻回报递推关系与终止态设定
  - 分幕式任务与持续性任务
- 策略与价值函数
  - 策略定义：状态到动作选择概率的映射
  - 状态价值函数与动作价值函数
  - 贝尔曼期望方程：状态价值递归自洽等式
  - 备份图：期望更新的数据流向与树状图解
- 最优策略与最优价值函数
  - 策略偏序关系与最优策略的存在性
  - 最优状态价值与最优动作价值
  - 贝尔曼最优方程（引入非线性最大化算子）
  - 压缩映射定理：保证迭代收敛至唯一不动点
  - 最优策略提取：基于最优动作价值直接贪婪选择

第4章：动态规划

- 核心前提与理论基石
  - 上帝视角：假设环境模型完备已知
  - 核心思想：将贝尔曼等式转化为赋值迭代
- 策略评估
  - 预测问题：在固定策略下迭代求解真实价值
  - 全宽期望更新：穷举后继状态加权平均
  - 不动点迭代与压缩映射收敛保证
- 策略改进
  - 策略改进定理：贪婪更新保证新策略单调不劣
  - 基于动作价值的单步前瞻贪婪化选择
- 策略迭代
  - 交替执行完全策略评估与贪婪策略改进
  - 经典应用算例：杰克租车问题
- 值迭代
  - 截断评估：每轮仅做单步最优备份直接融合
  - 经典应用算例：赌徒问题
- 异步动态规划与广义策略迭代
  - 异步动态规划：原位就地更新与优先级清扫
  - 广义策略迭代：评估与改进相互博弈协作的统合范式

第5章：蒙特卡洛方法

- 核心思想与根本特征
  - 无模型学习：纯粹从采样经验轨迹中学习
  - 仅限分幕式任务：回合彻底结束拿到完整回报才更新
  - 不自举：各状态价值估计相互独立
- 蒙特卡洛预测
  - 首次访问型与每次访问型
  - 基于大数定律用样本回报均值逼近真实期望
- 动作价值估计与探索保证
  - 无模型控制必须估计动作价值
  - 探索起始条件：强制所有状态动作对均有初试机会
- 同策略控制
  - 摆脱探索起始假设：引入软策略与ε-贪婪策略
  - 在生成经验数据的同时保持持续试错探索
- 异策略控制与重要性采样
  - 双策略分离：目标策略（最优评估）与行为策略（数据采样）
  - 覆盖假设：行为策略必须覆盖目标策略动作空间
  - 重要性采样比率：校准不同策略轨迹产生概率的权重
  - 普通重要性采样（无偏高方差）与加权重要性采样（有偏低方差）
  - 增量式实现与异策略控制（经典算例：赛道问题）

第6章：时序差分学习

- 核心思想与机制对比
  - 无模型与自举结合（兼具MC无模型与DP自举优势）
  - 单步在线即时更新（无需等待回合彻底终止）
  - 价值更新机制对比（DP全宽期望 / MC整轨采样 / TD单步自举）
- 时序差分预测
  - TD Target 与 TD Error（衡量一步之后的新信息与预测偏差）
  - 批处理 TD(0) 与确定性等价估计
  - 收敛性与方差特性（方差显著低于MC且收敛速度更快）
- 同策略控制：Sarsa
  - 经验五元组在线就地更新
  - 广义策略迭代结合 ε-贪婪探索驱动策略单调改进
  - 经典应用算例：有风网格世界（国王移动与对角线动作优化）
- 异策略控制：Q-learning
  - 行为策略（数据采集）与目标策略（纯贪婪评估）解耦
  - 离策略直接逼近贝尔曼最优方程
  - 典型算例：悬崖寻路（Sarsa保守安全路径 vs Q-learning激进最优路径）
- 期望时序差分：Expected Sarsa
  - 对下一状态所有可选动作依目标策略概率加权期望更新
  - 消除下一动作采样的随机方差，大幅提升学习稳定性
  - 离策略泛化：天然无需重要性采样比率权重
- 最大化偏差与双重学习
  - max 非线性算子在噪声环境下引入正向系统高估偏差
  - 解耦动作选择与动作评估（双动作价值估计）
  - Double Q-learning 算法机制与偏差消除
- 事后状态
  - 智能体决策后环境确定性转移产生的中间状态
  - 规则已知博弈（如井字棋/棋类）中的状态空间大幅压缩
  - 跨动作等价状态的快速价值泛化与学习效率倍增

第13章：策略梯度方法

- 核心范式跃迁
  - 隐式策略，动作价值驱动
  - 显式策略，参数化概率分布，直接映射状态至动作选择概率
  - 决策机制与价值函数解耦
- 策略参数化与四大核心优势
  - 离散动作空间建模：数值动作偏好函数与指数 Softmax 策略分布
  - 动作偏好无特定物理真值约束，可连续平滑无限逼近确定性策略
  - 能够自然发现并表达最优随机策略
  - 策略决策边界往往比复杂动作价值函数更简洁，参数学习效率更高
  - 便于将物理控制律形态等领域先验知识直接注入策略网络结构
- 策略梯度定理
  - 状态分布依赖难题：策略参数同时影响动作选择与未知环境状态转移分布
  - 策略梯度定理核心突破：巧妙消去状态分布对参数的导数项，给出免模型解析梯度表达式
  - 期望形式与似然比对数技巧
- REINFORCE：蒙特卡洛策略梯度
  - 从全动作求和更新到单样本动作重要性配凑采样与完整回报无偏替代
  - 一阶微分与探索利用平衡
  - 线性 Softmax 资格向量
  - 蒙特卡洛全轨迹累积随机性导致的高方差与慢收敛缺陷
- 带基线的 REINFORCE
  - 引入与动作无关的状态基线：消除回报常数偏移失真，大幅平抑样本方差
  - 状态价值基线与蒙特卡洛优势估计
- Actor-Critic
  - 从带基线 REINFORCE到 Actor-Critic
  - 单步 TD 误差与优势函数等价性：单步截断自举误差在期望上严格等于真实优势函数）
  - 偏差与方差权衡：单步自举使方差毁灭性暴跌，可控的函数逼近偏差换取压倒性的在线学习效率
- 持续性任务的策略梯度
  - 无终止任务困境与平均奖励率性能度量指标
  - 遍历性平稳分布不变性与差分回报重塑持续性贝尔曼方程
  - 单步差分 Actor-Critic 算法
- 连续动作空间的策略参数化
  - 连续概率密度函数（PDF）统计参数学习
  - 条件高斯策略分布：均值网络与指数标准差网络
  - 随机高斯策略与确定性策略

强化学习数学原理：值函数近似与深度 Q 网络

- 从表格型表示到函数逼近
  - 表格法特征
  - 函数法特征
  - 逼近代价与模型容量权衡
- 状态价值估计与误差目标体系
  - 平稳分布加权：马尔可夫链极限状态分布与转移矩阵左特征向量
  - 梯度优化演进：全局期望真实梯度下降转化为单样本随机梯度下降
  - 代用目标引入：蒙特卡洛完整回报替代与单步 TD 自举替代
  - 函数逼近器选型：线性特征基内积与非线性人工神经网络
  - 三大误差目标几何辨析：真实价值误差、贝尔曼误差、投影贝尔曼误差
- 带有值函数近似的控制算法
  - 从状态价值近似向动作价值近似的免模型控制迁移
  - 半梯度 Sarsa 与线性 Sarsa：同策略五元组在线参数更新与 ε-贪婪策略提升
  - 函数逼近 Q-learning：离策略贝尔曼最优最大化自举目标更新
- 深度 Q 网络
  - 均方贝尔曼最优误差目标与参数双端耦合的求导震荡困境
  - 双网络机制：实时更新的主网络与周期硬同步的冻结目标网络
  - 经验回放机制：均匀随机抽样逼近理论均匀分布假设、最大化数据复用效率
  - 网络结构选型：状态-动作拼接单输出结构 vs 状态输入并行多动作输出结构

强化学习数学原理：随机近似与随机梯度下降

- 增量式均值估计
  - 算术平均从批处理到增量式迭代递推展开
  - 步长序列衰减率对收敛性与非平稳跟踪特性的权衡影响
- Robbins-Monro 算法
  - 未知黑盒单调函数在带噪观测下的求根理论基石
  - RM收敛条件（步长和发散保证步长足够、平方和收敛有效抑制方差）
  - 算法几何收缩性与以概率 1 收敛保证
- 随机梯度下降视角统一
  - 均值估计二次损失函数极小化优化过程
  - BGD、MBGD 与 SGD 的样本梯度方差对比
- 强化学习算法收敛性大一统
  - TD(0) 状态价值估计本质：求解贝尔曼期望方程根的 RM 算法
  - Q-learning 控制算法本质：求解贝尔曼最优方程根的 RM 算法
  - 噪声样本与单步自举猜测下以概率 1 收敛的数学闭环

Presented with xmind