

# 学习周报

汇报人：张嘉伟

汇报周期：2026.09.12 - 2026.09.19

学习教材：《Reinforcement Learning: An Introduction》(Richard S. Sutton & Andrew G. Barto)

笔记与代码仓库：[Jwei-Z/rl\\_control\\_notes](#)

## 一、学习方法与心得体会

本阶段我的主要学习方法是直接研读原版英文专业文献/教材：

- 另一方面也能提升专业英语阅读速度与文献理解能力同时获取到系统性的专业知识。
- 记笔记的同时复习一些概率论知识，并且相关关键知识数学原理进行手推加深印象。
- 整理的完整 Markdown 笔记、Python 实验代码，均已同步推送到个人的 GitHub 仓库 ([rl\\_control\\_notes](#))。

## 二、本周学习内容概览

本周系统完成了教材前两章的精读，并推进了第三章的前半部分内容：

- Chapter 1: Introduction**
  - 了解了强化学习的基本定义与核心范式；
  - 学习了马尔可夫决策过程提出背景。
- Chapter 2: Multi-armed Bandits**
  - 强化学习中的**探索与利用**权衡难题；
  - 动作价值评估方法，包括经典的  $\epsilon$ -贪婪策略、乐观初始值方法、置信区间上界方法 (UCB) 以及梯度老虎机等探索机制；
  - 了解了“平稳环境”与“非平稳环境”。
- Chapter 3: Finite Markov Decision Processes (学习中)**
  - 学习了状态、动作、即时奖励与状态转移概率等系统动力学的形式化描述；
  - “智能体与环境的划分边界”；
  - 学习了回报、折扣因子以及分幕式任务和持续性任务的定义与建模方式。

## 三、课后习题与算法编程复现

为了检验对理论的掌握程度，本周完成了对应章节的课后思考题，并重点编写了代码复现其中的仿真实验：

- 完成相关习题**，对于一些有不了解的或者值得注意的习题已记录在笔记中。
- 非平稳老虎机 (Exercise 2.5)**：用 Python 编写了 10 臂老虎机仿真环境，其实验是在非平稳环境下，“样本平均法”和“固定步长法”的表现。
- 多算法全景参数敏感度对比 (Exercise 2.11)**：完成多种算法比如以及相关消融实验，主要包括  $\epsilon$ -greedy、UCB、梯度老虎机和乐观初始值在不同超参数下的表现。

## 四、 下周学习计划

---

- 顺着目前的进度继续推进后续章节的学习。
- 保持边读边写代码验证的习惯，遇到编程题继续动手复现，踏实把后面的核心算法弄懂，以及搞懂相关数学原理。