

学习周报

汇报人：张嘉伟

汇报周期：2026.09.21 - 2026.09.27

学习教材：《Reinforcement Learning: An Introduction》、《强化学习的数学原理》（赵世钰 著）及 B 站配套视频课程

笔记与代码仓库：[Jwei-Z/rl_control_notes](#)

一、学习方法与心得体会

本阶段我的主要学习方法是结合原版英文教材与数学原理视频课程协同推进：

- 两本书与视频课程结合学习**：先自主阅读 Sutton 英文原版教材并整理初步笔记；随后观看赵世钰老师《强化学习的数学原理》B 站配套视频章节，加深对贝尔曼方程、不动点迭代等底层数学原理的理解；对于此前理解不透彻或有新领悟的地方，再回过头来补充和完善笔记。
- 心得**：从第 3 章后半部分的贝尔曼最优方程，到第 4 章基于完备模型的动态规划，再到第 5 章真正走向无模型的蒙特卡洛方法。特别是看到算法如何逐步摆脱对环境模型的依赖、仅凭采样经验就能逼近最优策略，每一个式子都有其明确的物理意义而不仅仅是数学上的公式与算出来的结果，能看出来在书中的例子 Agent 是如何靠着式子一步步迭代走向最优，学起来有逻辑与获得感。
- 资料整理**：整理的完整 Markdown 笔记以及 Python 仿真实验代码，均已同步推送到个人的 GitHub 仓库。

二、本周学习内容概览

本周完成了第 3 章后半部分，第 4 章与第 5 章的全部内容：

1. Chapter 3: Finite Markov Decision Processes

- 学习了状态价值函数与动作价值函数，推导了贝尔曼期望方程；
- 掌握了最优策略与最优价值函数，理解了贝尔曼最优方程、压缩映射定理保证收敛的不动点迭代思想，以及从最优价值向最优策略贪婪提取的机制。

2. Chapter 4: Dynamic Programming

- 理解了 DP 基于环境模型完全已知的前提假设，以及将贝尔曼自治方程转化为计算机赋值迭代的核心理念；
- 学习了策略评估与策略改进；
- 掌握了策略迭代与值迭代的区别与联系，了解了异步动态规划与广义策略迭代的统一框架。

3. Chapter 5: Monte Carlo Methods

- 学习了无模型强化学习的基本范式，理解了蒙特卡洛方法仅限分幕式任务且不自举的核心特征；
- 学习了首次访问型与每次访问型蒙特卡洛预测，基于大数定律用样本回报逼近真实期望；
- 掌握了蒙特卡洛控制体系：从探索起始条件，到 On-policy，再到 Off-policy；
- 理解异策略中的重要性采样机制，以及权重更新的增量式实现。

三、课后习题与算法编程复现

完成了对应章节的配套习题。

- 重点习题已记录在笔记中。
- 以理解伪代码为主以及其矩阵运算的思想，相关伪代码等放在对应课后习题笔记中。
- 杰克租车 (Exercise 4.7)：策略迭代算法，在泊松分布需求下迭代计算两租车点的状态价值函数，成功收敛并绘制出最优车辆调度策略图。
- 赌徒 (Exercise 4.9)：值迭代算法，分析了不同硬币获胜概率 p_h 对状态价值和最优下注策略的影响，复现了不同迭代轮次下的策略图。
- 赛道 (Exercise 5.12)：带加权重要性采样的异策略蒙特卡洛控制算法，在离散网格赛道上成功训练出具备加速度控制与防撞急刹能力的最优行车轨迹。

四、下周学习计划

- 顺着目前的进度继续推进后续章节的学习，预计下周结束强化学习6，13章的课程，完成强化学习的数学原理课程的学习。
- 搞懂掌握相关数学原理。